Itens de Prova Paraná de Matemática na perspectiva da TCT, TRI e IA.

Raphael Fernandes Corrêa[1], Edy Célia Coelho[2], Anderfabio O. dos Santos[3], Jussielli de Oliveira[4], Fernando Moretti F. Nabarro[5]

[1] MBA, Secretaria de Estado da Educação, Curitiba, Paraná, Brasil e raphacorrea@gmail.com

[2] Doutora, Secretaria de Estado da Educação, Curitiba, Paraná, Brasil e edyceliacoelho@gmail.com

[3] Mestre, Secretaria de Estado da Educação, Curitiba, Paraná, Brasil e anderfabio.santos@escola.pr.gov.br

[4] Mestre, Secretaria de Estado da Educação, Curitiba, Paraná, Brasil e jussielli.oliveira@escola.pr.gov.br

[5] Mestre, Secretaria de Estado da Educação, Curitiba, Paraná, Brasil e fernando.nabarro@escola.pr.gov.br

Resumo

Este estudo analisou a capacidade de um modelo de inteligência artificial (IA) de estimar, a dificuldade de 22 itens de Matemática da primeira edição da Prova Paraná 2025, aplicada à 3.ª série do Ensino Médio. Desenvolvido a partir de itens do Exame Nacional do Ensino Médio, o modelo considerou características cognitivas das questões, e suas estimativas foram comparadas ao percentual de acertos da Teoria Clássica dos Testes e ao parâmetro de dificuldade da Teoria de Resposta ao Item. Os resultados revelaram correspondências e divergências entre as três abordagens, indicando que a IA pode oferecer informações complementares durante a elaboração e a revisão dos instrumentos, sem substituir o julgamento de especialistas, a aplicação aos estudantes ou as análises pedagógicas e psicométricas.

Palavras-chave: Dificuldade do Item; Teoria Clássica dos Testes; Teoria de Resposta ao Item; Inteligência artificial.

1 Introdução

A avaliação educacional subsidia a reflexão sobre os processos de ensino e aprendizagem (PENIN; MARTÍNEZ, 2009) e, em sua dimensão diagnóstica, permite verificar a presença ou ausência das habilidades necessárias à continuidade das aprendizagens (SANT'ANNA, 2024). Nesse contexto, a Prova Paraná integra o Sistema de Avaliação da Educação Básica do Paraná (SAEP) e, em 2025, foi realizada em duas edições, sendo aplicada para 98 192 estudantes, o que corresponde a 87% de participação e confere maior robustez aos resultados**,** avaliando habilidades das Matrizes de Referência dos diferentes componentes e etapas de ensino.

Na análise dos itens, a Teoria Clássica dos Testes (TCT) fornece indicadores de interpretação direta, como o percentual de acertos, enquanto a Teoria de Resposta ao Item (TRI) examina seu funcionamento pelos parâmetros de discriminação, dificuldade e probabilidade de acerto ao acaso; ambas, porém, só produzem evidências após a aplicação. A dificuldade importa para a composição do instrumento, pois provas com itens predominantemente muito fáceis ou muito difíceis cobrem mal os níveis de proficiência; sem pré-testagem, ela é estimada por julgamentos técnicos e pedagógicos.

Métodos de inteligência artificial (IA) podem acrescentar informações a esse processo ao analisar as demandas cognitivas dos itens e estimar sua dificuldade antes da aplicação. O uso recente da IA na avaliação educacional inclui a geração, a revisão e a análise de itens (HAO et al., 2024; SAYIN; GIERL, 2024). A dificuldade estimada pela IA não equivale a um parâmetro psicométrico nem substitui a aplicação aos estudantes, mas pode constituir informação complementar durante a elaboração.

Diante disso, este estudo analisa a capacidade de um modelo de IA de estimar a dificuldade de 22 itens de Matemática da primeira edição da Prova Paraná 2025, aplicada à 3.ª série do Ensino Médio. As estimativas são comparadas ao percentual de acertos da TCT e ao parâmetro de dificuldade do modelo 3PL da TRI, para verificar a correspondência entre as medidas e discutir possibilidades e limitações da IA na revisão prévia de itens.

2 Metodologia

Este estudo, quantitativo e exploratório, tomou como unidades de análise os 22 itens de Matemática da primeira edição da Prova Paraná 2025, aplicada à 3.ª série do Ensino Médio, e as respostas de estudantes, elaborados com base na Matriz de Referência e sem pré-teste ou calibração prévia.

A dificuldade foi examinada por três perspectivas. Na TCT, o índice de dificuldade é a proporção de respostas corretas: quanto menor, maior a dificuldade no grupo avaliado. Para a classificação, adotaram-se os intervalos de Cerdá (1978): muito difícil (0,05–0,25), difícil (0,25–0,45), médio (0,45–0,55), fácil (0,55–0,75) e muito fácil (0,75–0,95).

Na TRI, empregou-se o Modelo Logístico de Três Parâmetros (3PL) (BIRNBAUM, 1968), estimado no R com o pacote *mirt* (CHALMERS, 2012), obtendo-se os parâmetros de discriminação (a), dificuldade (b) e acerto ao acaso (c). A comparação concentrou-se no b, em que valores mais elevados indicam maior dificuldade; a e c caracterizam complementarmente o funcionamento dos itens.

A terceira medida foi produzida por um modelo preditivo desenvolvido com 705 itens de Matemática das edições regulares do Exame Nacional do Ensino Médio (ENEM) entre 2009 e 2025, exceto 2020 (INEP, 2025). Adotaram-se os parâmetros oficiais como referência; paralelamente, o grupo desenvolveu uma recalibração do 3PL por rede neural rasa (BASTOS,

2024), não utilizada nos resultados aqui reportados. Cada item foi representado por seis características da demanda de resolução (FISCHER, 1973; DE BOECK; WILSON, 2004): número de passos, nível de abstração, carga de leitura, cálculo intensivo, dependência de figura e relevância do contexto. Os descritores foram atribuídos por um modelo de linguagem de grande escala (Claude Opus 5), operado com esforço de raciocínio estendido, que resolvia cada item antes de contabilizar as etapas, em ordem aleatorizada e sem acesso aos parâmetros calibrados. Padronizados, serviram de variáveis explicativas em uma regressão *ridge* (HOERL; KENNARD, 1970), tendo como variável dependente a dificuldade relativa dos itens do ENEM — a combinação é linear e regularizada, e não uma rede neural: o aprendizado profundo restringe-se à leitura e à codificação do enunciado.

A generalização foi avaliada por *leave-one-year-out*: em cada rodada, os itens de uma edição completa do ENEM eram excluídos do treinamento e usados na validação, de modo que suas dificuldades fossem estimadas por um modelo sem contato prévio com eles. Em seguida, validou-se externamente com os 22 itens da Prova Paraná, ausentes do treinamento.

Por utilizarem escalas distintas, as medidas da TCT, da TRI e do modelo preditivo foram comparadas principalmente pela ordenação dos itens, com a correlação de postos de Spearman e a proporção de pares corretamente ordenados. Examinou-se também a concordância entre as categorias de dificuldade da TCT e da TRI e, individualmente, os casos de maior convergência e divergência.

3 Resultados

A Tabela 1 apresenta o comportamento dos 22 itens: na TCT, as proporções de respostas em cada alternativa, o percentual de acertos e a classificação de dificuldade; na TRI, os parâmetros a, b e c, com as respectivas classificações.

Tabela 1: **Resultados dos itens de Matemática segundo a TCT e a TRI**

		TCT							TRI				
Localização	itemcode	A	B	C	D	E	% ACERTO	Classificação do Item	a	b	c	Classificação da Dificuldade - DIF	Classificação da Discriminação
1	MT31061PR25	11,43	9,88	48,41	12,11	17,71	48,41	Médio	1,24	0,63	0,20	Difícil	Moderada
2	MT31062PR24	63,77	9,81	10,74	7,20	8,13	63,77	Fácil	1,31	-0,56	0,00	Fácil	Moderada
3	MT31141PR25	21,65	22,19	17,70	22,54	14,60	21,65	Muito difícil	3,12	1,63	0,15	Difícil	Muita alta
4	MT31142PR25	18,19	21,69	39,01	11,82	8,92	39,01	Difícil	2,33	0,96	0,21	Difícil	Muita alta
5	MT31181PR25	11,86	9,89	17,62	14,12	45,80	45,80	Médio	2,05	0,58	0,19	Difícil	Muita alta
6	MT31182PR25	16,63	12,53	22,38	33,66	14,23	33,66	Difícil	2,65	1,18	0,21	Difícil	Muita alta
7	MT31191PR25	14,04	52,23	13,58	12,04	7,58	52,23	Médio	1,52	0,04	0,06	Médio	Alta
8	MT31192PR25	67,11	6,96	10,92	5,15	9,39	67,11	Fácil	2,13	-0,48	0,07	Médio	Muita alta
9	MT31201PR25	7,29	7,58	6,55	58,40	19,78	19,78	Muito difícil	1,89	2,21	0,15	Muito difícil	Muita alta
10	MT31202PR25	4,27	12,02	4,76	32,09	46,23	32,09	Difícil	1,09	1,00	0,04	Difícil	Moderada
11	MT31211PR25	7,63	11,86	14,18	57,00	8,42	57,00	Fácil	1,20	-0,29	0,00	Médio	Moderada
12	MT31212PR25	65,32	7,38	10,25	8,42	8,25	65,32	Fácil	1,48	-0,59	0,00	Fácil	Alta
13	MT31271PR24	11,80	16,32	19,81	26,06	25,09	19,81	Muito difícil	2,97	1,90	0,16	Difícil	Muita alta
14	MT31271PR25	11,47	31,65	27,18	16,87	11,88	27,18	Difícil	3,89	1,41	0,19	Difícil	Muita alta
15	MT31281PR25	15,46	21,43	20,35	20,56	21,03	21,03	Muito difícil	2,43	1,91	0,16	Difícil	Muita alta
16	MT31291PR25	10,20	36,32	24,11	13,93	14,98	36,32	Difícil	3,28	1,03	0,22	Difícil	Muita alta
17	MT31292PR25	20,01	40,69	14,45	11,19	12,76	40,69	Difícil	1,90	1,31	0,29	Difícil	Muita alta
18	MT31Hd271PR25	19,06	13,20	25,82	18,51	22,01	22,01	Muito difícil	2,76	1,83	0,17	Difícil	Muita alta
19	MT31Hd272PR25	12,93	16,14	22,91	36,49	11,07	36,49	Difícil	1,49	1,08	0,16	Difícil	Alta
20	MT31Hd291PR25	13,24	31,04	21,92	13,67	19,34	31,04	Difícil	3,00	1,44	0,23	Difícil	Muita alta
21	MT31Hd292PR25	15,29	16,09	44,45	13,79	9,96	44,45	Difícil	2,65	0,71	0,23	Difícil	Muita alta
22	MT31d281PR24	18,76	45,30	14,01	13,63	7,88	45,30	Médio	1,38	0,61	0,15	Difícil	Alta

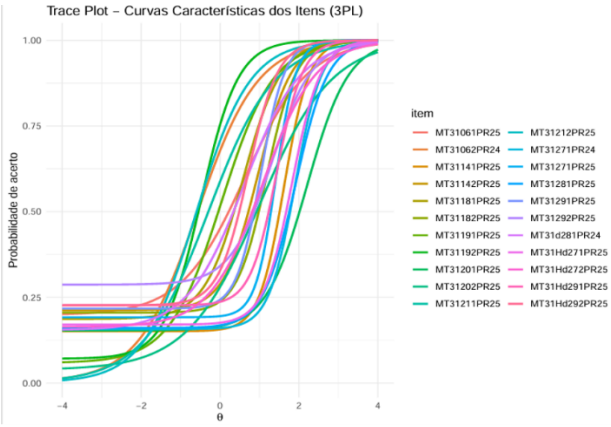
Os 22 itens distribuíram-se entre diferentes níveis de dificuldade, não havendo itens classificados como muito fáceis. Entre TCT e TRI, 12 itens (54,5%) receberam a mesma

classificação e 10 (45,5%) foram classificados em categorias distintas, sempre próximas, sem oposição entre os extremos de dificuldade.

Orientadas no mesmo sentido de dificuldade, as duas medidas apresentaram correlação de Spearman de ρ = 0,965, evidenciando elevada correspondência na ordenação dos 22 itens (Figura 2a).

Quanto à discriminação, 14 itens foram classificados como de discriminação muito alta, quatro como alta e quatro como moderada, não sendo identificados itens com discriminação baixa ou inadequada. O parâmetro c, associado à probabilidade de acerto ao acaso, situou-se entre 0,00 e 0,29, conforme a Figura 1.

Figura 1: **Curva Característica do Item (CCI)**



Incorporadas à análise as estimativas do modelo de IA e considerando que as três medidas utilizam escalas distintas, a comparação foi realizada pela ordenação dos itens. A correlação da IA foi de ρ = 0,520 com o parâmetro b da TRI e de ρ = 0,457 com o percentual de acertos da TCT; na validação externa, o modelo apresentou 70% de ordenação correta dos pares de itens.

A Figura 2 (b) apresenta a posição relativa dos 22 itens nos três ordenamentos. No eixo horizontal, estão os itens conforme sua localização na Tabela 1, enquanto o eixo vertical indica sua posição no ordenamento de dificuldade.

Figura 2 – (a) **Relação entre o percentual de acertos (TCT) e o parâmetro de dificuldade b (TRI);**

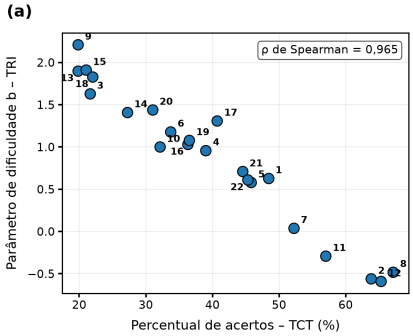
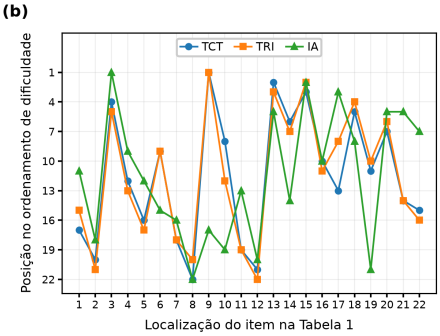


Figura 2 – (b) **Ordenação dos 22 itens segundo a dificuldade indicada pela TCT, pela TRI e pela IA.**



A comparação individual mostra situações de grande proximidade entre os três ordenamentos: o MT31281PR25 ocupou a 3.ª posição pela TCT, a 2.ª pela TRI e a 2.ª pela IA,

e o MT31271PR24, as posições 2, 3 e 5. No outro extremo, o MT31192PR25 ficou em 22.º, 20.º e 22.º.

Também foram registradas diferenças acentuadas. O MT31201PR25, com 19,78% de acertos e b = 2,21, ocupou a primeira posição pela TCT e pela TRI, mas a 17.ª pela IA; o MT31Hd272PR25 ocupou as posições 11, 10 e 21. Em sentido inverso, o MT31292PR25 foi o 13.º pela TCT, o 8.º pela TRI e o 3.º pela IA.

3.1 Discussão

A comparação entre TCT e TRI apresentou elevada consistência ($\rho = 0{,}965$), indicando ordenação semelhante dos itens quanto à dificuldade; as diferenças pontuais entre categorias não alteraram a identificação dos itens mais e menos difíceis. A predominância de itens com discriminação alta ou muito alta indica capacidade de diferenciar estudantes situados em distintos níveis de proficiência.

Em relação à IA, as correlações foram inferiores às observadas entre TCT e TRI, com $\rho = 0{,}520$ em relação ao parâmetro *b* da TRI e $\rho = 0{,}457$ em relação à TCT. A validação externa apresentou 70% de ordenação correta dos pares de itens. Esses resultados indicam aproximação entre a dificuldade prevista pela IA e aquela observada após a aplicação, mas revelam que essa capacidade de antecipação não ocorreu de maneira uniforme entre os itens.

As divergências decorrem, em parte, da natureza distinta das medidas: TCT e TRI partem das respostas efetivamente produzidas pelos estudantes, ao passo que a IA estima previamente a dificuldade a partir das características dos itens. Número de passos, abstração, carga de leitura, presença de cálculos, figuras e contexto contribuem para a previsão, mas não explicam isoladamente a dificuldade, que também depende do conhecimento e da estratégia necessários à resolução.

A análise estatística pode ainda ser ampliada pela interpretação pedagógica dos itens: a articulação entre percentual de acertos, parâmetros da TRI, comportamento dos distratores e habilidade avaliada permite levantar hipóteses sobre os processos de resolução e sobre os conhecimentos ainda não consolidados, perspectiva particularmente relevante em uma avaliação de caráter diagnóstico (SANT'ANNA, 1995).

Os resultados sugerem, portanto, papel complementar da IA em etapa anterior à aplicação: durante a elaboração e a revisão, ela pode auxiliar na identificação prévia de questões cuja dificuldade estimada esteja distante do nível pretendido. As divergências encontradas mostram, porém, que a IA não deve substituir as análises psicométricas baseadas nas respostas dos estudantes, e sim atuar como fonte adicional de evidências.

Entre as limitações do estudo, destacam-se o número reduzido de itens utilizados na validação externa, composto por 22 questões, e a possibilidade de viés decorrente da anotação dos descritores dos itens externos não ter ocorrido de forma completamente independente dos parâmetros calibrados. Assim, a ampliação da quantidade de itens, a realização de anotações independentes e a aplicação do modelo em diferentes edições da avaliação são necessárias para verificar a estabilidade dos resultados.

4 Conclusões e Considerações Finais

Este estudo comparou a dificuldade de 22 itens de Matemática da Prova Paraná sob três perspectivas: a TCT, a TRI e um modelo de IA que estima a dificuldade antes da aplicação. A forte relação entre TCT e TRI ($\rho = 0{,}965$) contrasta com a aproximação moderada da IA ($\rho = 0{,}520$ com a TRI e $\rho = 0{,}457$ com a TCT, além de 70% de pares corretamente ordenados), próxima em parte dos itens e divergente em outros.

A IA não substitui a análise pedagógica, a revisão técnica nem as análises psicométricas já realizadas pela Coordenação de Avaliação (CAV), mas acrescenta uma informação hoje indisponível: uma estimativa de dificuldade obtida ainda durante a elaboração, capaz de sinalizar itens distantes do nível pretendido antes que integrem o instrumento. A ampliação do número de itens, a realização de anotações independentes e a aplicação do modelo em outras edições são os próximos passos para verificar a estabilidade das relações encontradas.

5 Referências

BASTOS, L. M. *Deep IRT: an application of deep learning methods to Item Response Theory*. Dissertação (Mestrado em Estatística) – Universidade de Brasília, Brasília, 2024.

BIRNBAUM, A. Some latent trait models and their use in inferring an examinee's ability. In: LORD, F. M.; NOVICK, M. R. *Statistical Theories of Mental Test Scores*. Reading: Addison-Wesley, 1968.

CHALMERS, R. P. mirt: a multidimensional item response theory package for the R environment. *Journal of Statistical Software*, v. 48, n. 6, p. 1–29, 2012.

DE BOECK, P.; WILSON, M. (Eds.). *Explanatory Item Response Models: a generalized linear and nonlinear approach*. New York: Springer, 2004.

FISCHER, G. H. The linear logistic test model as an instrument in educational research. *Acta Psychologica*, v. 37, n. 6, p. 359–374, 1973.

HAO, J.; VON DAVIER, A. A.; YANEVA, V.; LOTTRIDGE, S. M.; VON DAVIER, M.; HARRIS, D. J. *Transforming Assessment: The Impacts and Implications of Large Language Models and Generative AI.* Educational Measurement: Issues and Practice, v. 43, n. 2, p. 16–29, 2024. DOI: https://doi.org/10.1111/emip.12602

HOERL, A. E.; KENNARD, R. W. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, v. 12, n. 1, p. 55–67, 1970.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). *Microdados do ENEM*: edições de 2009 a 2025. Brasília: INEP, 2025.

PENIN, Sônia; MARTÍNEZ, Miguel. Profissão docente: pontos e contrapontos. São Paulo: Summus, p. 23-24, 2009.

SANT'ANNA, I. M. Por que avaliar? Como avaliar? Critérios e instrumentos. Petrópolis: Vozes, 1995.

SAYIN, A.; GIERL, M. J. Using OpenAI GPT to Generate Reading Comprehension Items. *Educational Measurement: Issues and Practice*, Hoboken, v. 43, n. 1, p. 5–18, 2024. Disponível em: https://doi.org/10.1111/emip.12590.