Monitoramento da Qualidade da Correção de Itens Abertos via Modelo Rasch Multifacetado: Aplicação à Avaliação Formativa do Ceará 2025

Gabriela Paschoal da Silva [1], Jaqueline Lamas da Silva [2], Davi Loures Paiva[3], Wellington Silva [4]

[1] Fundação Centro de Políticas Públicas e Avaliação da Educação – CAEd/UFJF; gabriela.paschoal@fundacaocaed.org.br

[2] Universidade de São Paulo - USP; jaqueline.lamas@usp.br

[3] Fundação Centro de Políticas Públicas e Avaliação da Educação – CAEd/UFJF; davi.paiva@fundacaocaed.org.br

[4] Fundação Centro de Políticas Públicas e Avaliação da Educação – CAEd/UFJF; wellington.silva@fundacaocaed.org.br

Resumo

A consistência na correção de itens de resposta construída é fator essencial para a qualidade das medidas educacionais produzidas, uma vez que variações de severidade ou diferenças de concordância entre corretores podem introduzir variabilidade indesejada nas pontuações. Nesse contexto, o presente trabalho teve como objetivo analisar o comportamento de corretores da Avaliação Formativa do Ceará 2025 via modelagem Rasch multifacetada. Ao total, foram considerados 9.188 estudantes, 64 corretores e 7 aspectos de correção. Os resultados evidenciaram elevados níveis de concordância entre os corretores, ajuste adequado para a maior parte dos avaliadores e dos aspectos considerados, e apenas poucos casos de desajuste com respeito à leniência/severidade. Por fim, concluiu-se que a modelagem Rasch multifacetada constitui uma ferramenta eficaz para o monitoramento da qualidade da correção em avaliações educacionais, podendo também subsidiar, em estudos futuros, a validação e o monitoramento de sistemas automatizados de correção baseados em inteligência artificial.

Palavras-chave: modelo rasch multifacetado; correção de itens de resposta construída; severidade de corretores; avaliação educacional.

1 Introdução

Segundo Linacre (1994), uma nota em avaliação pode ser compreendida como produto da interação entre elementos independentes, tais como alunos, itens e corretores. No caso de itens de resposta construída, a atribuição de escores depende do julgamento dos avaliadores, de modo que aspectos como as diferenças no grau de severidade (ou leniência), a concordância entre corretores ou a consistência da correção podem comprometer a qualidade e a comparabilidade das medidas produzidas. Nesse contexto, a modelagem Rasch multifacetada constitui uma importante ferramenta para investigar quantitativamente o comportamento dos corretores, permitindo estimar parâmetros relacionados à severidade, à concordância entre avaliadores e à dificuldade dos aspectos avaliados (Eckes, 2015).

Além do trabalho de avaliadores humanos, o emprego de sistemas baseados em inteligência artificial (IA) para apoio à correção de itens abertos tem se tornado cada vez mais frequente. Em termos da modelagem multifacetada, uma possibilidade seria incluir a IA na faceta dos corretores, de maneira a comparar esse sistema com os avaliadores humanos no que diz respeito à severidade e a concordância. Assim, abordagens fundamentadas na modelagem Rasch multifacetada apresentam potencial para subsidiar a validação e o monitoramento tanto de corretores humanos quanto de sistemas automatizados de correção.

Diante desse cenário, o presente estudo utiliza o modelo Rasch multifacetado para analisar o comportamento dos corretores de um item aberto da Avaliação Formativa do Ceará 2025, investigando aspectos relacionados ao ajuste, à severidade/leniência e à concordância entre esses profissionais, com o intuito de avaliar a qualidade das correções. Adicionalmente, discute-se o potencial dessa abordagem para aplicações futuras em contextos de IA na avaliação educacional.

2 Objetivos

Considerando as pontuações atribuídas por corretores humanos a um item aberto da Avaliação Formativa do Ceará 2025, bem como 7 aspectos utilizados no processo de correção, este estudo teve por objetivo analisar o ajuste dos corretores ao modelo Rasch multifacetado, buscando reunir evidências que permitissem validar (ou invalidar) a qualidade e a consistência do processo de correção. Além disso, objetivou-se obter e analisar as estimativas das competências individuais dos alunos (notas ou proficiências), da severidade (ou leniência) dos avaliadores, da concordância entre os corretores e da dificuldade dos aspectos avaliados, de

modo a caracterizar as diferentes facetas envolvidas no processo de avaliação (são elas: alunos, corretores e aspectos de pontuação) e fornecer subsídios para o monitoramento e o aprimoramento contínuo da qualidade da correção de itens abertos em avaliações em larga escala.

3 Metodologia

O presente estudo foi conduzido em três amostras diferentes, todas provenientes da Avaliação Formativa do Ceará 2025. As amostras consistiam em planilhas contendo as seguintes colunas de informações: código identificador do aluno, código identificador do corretor, código do item, além de colunas para os aspectos avaliados com as respectivas pontuações atribuídas pelos corretores. A formação de três conjuntos (ou amostras) ocorreu devido à ordem temporal de chegada dos dados. Os conjuntos foram compostos de forma que os alunos que tiveram seus testes corrigidos por apenas um corretor dentro de uma mesma amostra fossem desconsiderados. Ao total, foram contabilizados 9.188 alunos e 64 corretores únicos. Os corretores consideraram 7 aspectos de correção: (1) adequação à proposta, (2) tipologia textual, (3) uso da página, (4) ortografia, (5) pontuação, (6) coesão e (7) segmentação. Cada aspecto podia receber uma nota de 1 a 4. Então, utilizando o software FACETS (versão 3.71.4), foi feito o ajuste dos dados via modelagem Rasch multifacetada – dessa forma, foi possível obter e analisar as estimativas para as competências dos alunos, a severidade dos corretores e a dificuldade dos aspectos pontuados.

Para o estudo da concordância entre avaliadores, foram considerados os valores obtidos para a concordância observada e para a concordância esperada – o ideal é que a observada seja maior que a esperada, e quanto mais próxima de 100% a observada estiver, mais próximos os avaliadores estão de estarem trabalhando como um único corretor padrão (Linacre, 2014). Além disso, considerando as estatísticas *InfitMS* e *OutfitMS* – Infit Mean Square e Outfit Mean Square, respectivamente –, realizamos o estudo do ajuste dos corretores à modelagem proposta. Valores acima de 2 para essas estatísticas indicam corretores que distorcem ou degradam o sistema de medida (Linacre, 2014). Dessa forma, os avaliadores que se mostraram desajustados tiveram suas correções revisadas pela equipe responsável.

Com respeito ao estudo da severidade dos corretores, foram considerados apenas aqueles que apareceram em todos os três conjuntos de dados – isto é, 57 avaliadores ao todo –, com o

intuito de viabilizar a comparabilidade entre amostras. Para esses profissionais, foram analisados os gráficos de dispersão da severidade e o quantitativo de redações corrigidas, além de realizada a classificação em "leniente", "moderado" ou "severo" com base nos tercis da distribuição da severidade. A intenção com essas análises foi caracterizar o perfil de cada corretor e verificar se haveria consistência para esse perfil entre as amostras.

4 Resultados e Discussão

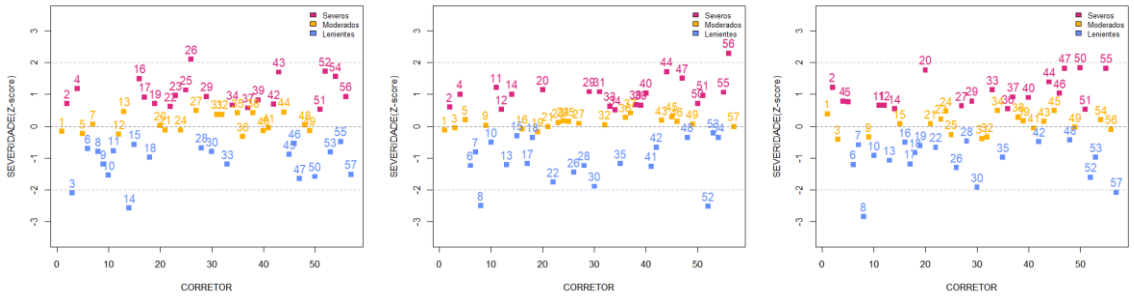
Dos 57 corretores em comum entre as amostras, apenas 2 apresentaram desajuste pelo critério das estatísticas *InfitMS* e *OutfitMS* – ou seja, apenas 2 corretores apresentaram valores maiores ou iguais a 2 para essas estatísticas (são eles: corretor 37 e corretor 56). A Figura 1 apresenta a distribuição dos corretores por faixa de *InfitMS* e *OutfitMS*, considerando as estimativas obtidas para cada amostra (um indivíduo se repete entre os que se mostraram desajustados, resultando em apenas 2 desajustados). Esses corretores tiveram seus processos de correção revisados.

Com relação à concordância entre os corretores, obtivemos que eles estão bem alinhados, pois os valores obtidos para a concordância observada em cada amostra (62%, 60% e 58%, respectivamente) foram maiores que aqueles obtidos para a concordância esperada (57%, 54% e 52%). Nos gráficos da Figura 2, é possível conferir a classificação de cada corretor em leniente, moderado ou severo de acordo com os tercis da distribuição da severidade, além de conferir como essa estimativa varia entre amostras para cada corretor.

Figura 1 – Distribuição dos corretores em comum entre amostras por categorias de *InfitMS* e *OutfitMS.*

Faixa	Amostra 1		Amostra 2		Amostra 3	
	OutfitMS	InfitMS	OutfitMS	InfitMS	OutfitMS	InfitMS
>= 2	0	0	0	1	1	1
[1,5;2,0)	1	0	4	2	6	3
[0,5;1,5)	56	56	52	54	50	53
< 0,5	0	1	1	0	0	0
Total	57	57	57	57	57	57

Figura 2 – Gráficos com as severidades dos corretores (identificados por números de 1 a 57) nas três amostras.



Os sete aspectos avaliados também se mostraram bem ajustados ao modelo (*InfitMS* e *OutfitMS* menores que 2), com parâmetros de dificuldade variando de -1,5 a 1,97 nas três amostras, sendo o aspecto 1 (adequação à proposta) o mais fácil e o aspecto 5 (pontuação), o mais difícil em todos os casos. Os aspectos 2 (tipologia textual), 4 (ortografia) e 6 (coesão) apresentaram estimativas intermediárias e próximas para a dificuldade – a Figura 3 apresenta as estimativas obtidas para cada amostra.

Figura 3 – Dificuldade estimada para cada aspecto e erro-padrão associado.

Aspecto	Amostra 1 Dificuldade (E.P.)	Amostra 2 Dificuldade (E.P.)	Amostra 3 Dificuldade (E.P.)
Adequação à proposta	-1,21 (0,04)	-1,40 (0,03)	-1,47 (0,03)
Tipologia Textual	0,32 (0,03)	0,55 (0,02)	0,49 (0,02)
Uso da página	-0,89 (0,03)	-0,75 (0,03)	-0,88 (0,03)
Ortografia	0,23 (0,03)	0,02 (0,03)	0,15 (0,03)
Pontuação	1,66 (0,02)	1,75 (0,02)	1,95 (0,02)
Coesão	0,32 (0,02)	0,42 (0,02)	0,33 (0,02)
Segmentação	-0,44 (0,03)	-0,60 (0,03)	-0,57 (0,03)

Por fim, as proficiências apresentaram distribuições normais e simétricas em torno das médias 1,75 (amostra 1), 1,36 (amostra 2) e 0,98 (amostra 3), o que sugere um alinhamento entre as competências dos alunos e as dificuldades dos aspectos avaliados.

5 Conclusão

Os resultados indicam que o processo de correção da Avaliação Formativa do Ceará 2025 apresenta evidências de consistência e adequação ao modelo *Rasch* multifacetado, com a maior parte dos corretores apresentando comportamento ajustado, elevados níveis de concordância e estabilidade na severidade entre as amostras. Os poucos casos de desajuste

foram identificados e encaminhados para revisão, demonstrando o potencial da modelagem como ferramenta de monitoramento da qualidade da correção. Além disso, o bom ajuste dos aspectos avaliados reforça a validade das medidas obtidas. Dessa forma, o modelo Rasch multifacetado se mostrou uma abordagem eficaz para avaliar a qualidade do processo de correção, subsidiando ações de formação, acompanhamento e aprimoramento contínuo dos corretores em avaliações educacionais em larga escala.

Adicionalmente, os resultados reforçam o potencial desta abordagem para aplicações futuras envolvendo sistemas automatizados de correção baseados em inteligência artificial. À medida que esses sistemas passam a integrar processos avaliativos, torna-se fundamental dispor de métodos capazes de monitorar sua consistência, identificar padrões de severidade ou leniência e avaliar sua concordância em relação aos critérios de correção estabelecidos. Nesse contexto, a modelagem Rasch multifacetada apresenta-se como uma estratégia promissora para validar e acompanhar o desempenho desses sistemas, permitindo inclusive a incorporação da IA na faceta dos corretores em estudos futuros. Em última análise, o uso conjunto da inteligência artificial e da modelagem Rasch multifacetada viabiliza correções mais ágeis, sob contínuo monitoramento, preservando a qualidade das medidas produzidas.

6 Referências

ECKES, T. *Introduction to Many-Facet Rasch Measurement: Analyzing and Evaluating Rater-Mediated Assessments.* 2. rev. and updated ed. Frankfurt am Main; Berlin; Bern; Bruxelles; New York; Oxford; Wien: Peter Lang GmbH, Internationaler Verlag der Wissenschaften, 2015.

LINACRE, J. M. *A user's guide to FACETS Rasch-model computer programs: program manual 3.71.4.* Chicago: Winsteps.com, 2014. Disponível em: https://www.winsteps.com. Acesso em 11 ago. 2026.

LINACRE, J.M. *Many-facet Rasch measurement.* 2. ed. Chicago: MESA Press, 1994.

MASTERS, G. N. A Rasch model for partial credit scoring. *Psychometrika*, v. 47, n. 2, p. 149-174, 1982. DOI: https://doi.org/10.1007/BF02296272

MYFORD, C. M.; WOLFE, E. W. Detecting and measuring rater effects using many-facet Rasch measurement: Part I. *Journal of Applied Measurement*, [s.l.], v. 4, p. 386–422, 2003.