Considerações sobre o Coeficiente de Confiabilidade

Ruben Klein[1], Thales Akira Ricarte[2], Alice Nabiça Moraes[3]

[1] Fundação Cesgranrio, ruben@cesgranrio.org.br ou kleinrub@gmail.com

[2] Fundação Cesgranrio, thales.ricarte@cesgranrio.org.br

[3] Fundação Cesgranrio, alicemoraes@cesgranrio.org.br ou alicennmoraes@gmail.com

Resumo

O coeficiente de confiabilidade ou fidedignidade é uma estatística da Teoria Clássica dos Testes que mede a precisão ou qualidade de um teste. Neste artigo recordamos três estimativas clássicas do coeficiente. Chama-se a atenção de que só podem ser aplicadas se houver correlação entre todos os itens do teste, o que depende do planejamento do teste. Pode-se também calcular uma confiabilidade empírica estimada pela Teoria de Resposta ao Item, que em princípio não tem esta limitação. Faz-se uma aplicação com os dados públicos do Saeb 2023.

Palavras-chave: Coeficiente de confiabilidade, fidedignidade, escore verdadeiro, confiabilidade empírica

1 Introdução

O coeficiente de confiabilidade ou fidedignidade é uma estatística da Teoria Clássica dos Testes que mede a precisão ou qualidade de um teste. É muito usado para se verificar a adequabilidade do teste. Este coeficiente envolve a noção de escore verdadeiro, ver Lord & Novick 1968, Klein 2005.

O coeficiente de confiabilidade ou fidedignidade é definido como o quadrado da correlação entre o escore observado e o escore verdadeiro (variável latente não observada). Obviamente não podemos usar essa definição diretamente, pois o escore verdadeiro não é conhecido. Este coeficiente costuma aumentar com o número de itens.

Apresentam-se as estimativas clássicas alpha de Cronbach, Guttman's G6 e McDonald ômega total, com as fórmulas apresentadas na seção de metodologia. Apresenta-se também a confiabilidade empírica obtida pela Teoria de Resposta ao Item

O objetivo do trabalho é mostrar a diferença entre a confiabilidade para todos os itens do teste, caso os alunos respondessem a todos e a confiabilidade de cada caderno, o cuidado no cálculo da variância do escore total do aluno, introduzir a confiabilidade empírica e exemplificar com dados reais disponibilizados pelo INEP do Saeb 2023 do 5º EF de Matemática.

A aplicação feita utiliza os dados públicos do teste de matemática para os alunos do 5º ano do ensino fundamental, que utiliza um planejamento de blocos incompletos balanceados (BIB) que garante a correlação entre quaisquer dois itens. Calcula-se a confiabilidade para o teste total e para cada caderno de teste e a confiabilidade empírica. Mostra-se que as confiabilidades dos cadernos são semelhantes, importante para a adequabilidade do teste. Estas confiabilidades são menores que a confiabilidade do teste total. A confiabilidade empírica, neste caso, foi semelhante a de cada caderno.

2 Metodologia

Na teoria clássica dos testes, o escore observado X é modelado por X = T + E, onde T é o escore verdadeiro e E o erro de medida. Supõe-se que T e E são não correlacionados e que a média do erro E é zero.

Tem-se que $\mathrm{cov}(\mathrm{X},\mathrm{T}) = V(T)$

e que

$$\begin{aligned} \text{coeficiente de confiabilidade} \;=\; \mathrm{cor}(\mathrm{X},\mathrm{T})^2 \;&=\; \mathrm{cov}(\mathrm{X},\mathrm{T})^2 \,/\big(V(X)V(T)\big) \\ &=\; V(T)/V(X) \\ &=\; 1-(V(E)/V(X)). \end{aligned} \qquad (1)$$

Seja $X = (X_{ij})$, $i = 1,\dots,n$, $j = 1,\dots,J$, n o número de indivíduos, J o número de variáveis (itens) e X_{ij} é o escore do indivíduo i na variável (item) j, $X_i = \sum_j X_{ij}$ é o escore total do indivíduo i e $X_j = (X_{1j}, X_{2j}, \dots, X_{nj})$ vetor da variável j.

Seja V a matriz $J \times J$ de covariância de $(X_1, \dots, X_J)$,

Seja V_X a variância de $X = (X_1, X_2, \dots, X_n)$, que é conhecida, pois. X_i é conhecido, o problema é estimar $V(T)$ ou $V(E)$.

Observação: V_X tem que ser calculado a partir da matriz de covariância, $V_X = sum(V)$, se os dados não forem completos, por exemplo, se houver item não apresentado a um indivíduo. A matriz de covariância é calculada pelas observações completas por par. ("pairwise.complete.obs")

Há várias estimativas do coeficiente de confiabilidade. A mais comum é o alpha de Cronbach dado por

$$alpha\ de\ Cronbach = (J/(J-1))(1 - tr(V)/V_X)) \quad (2)$$

Observe que $tr(V) = \sum V(X_j)$.

Temos também Guttman's Lambda 6 (G6) dada por:

$G6 = 1 - \left(\sum e_j^2/V_X\right)$ onde $e_j^2 = 1 - r_{smc}^2$, em que o r_{smc}^2 é o quadrado da correlação múltipla da variável j nas outras variáveis. O r_{smc}^2 é um limite inferior para a comunalidade do item.

Outra estimativa é o ômega$_t$ ω_t (ômega total) de McDonald que estima o erro usando a comunalidade do item j. Usamos uma dimensão.

$$\omega_t = 1 - \left(\sum e_j^2/V_X\right), e_j^2 = 1 - h_j^2 \quad (3)$$

A função ômega do pacote psych (Revelle, 2019) para o R, calcula estas 3 estimativas. A função alpha do psych também calcula o alpha e o G6, mas não o ômega total. Observe que tanto a função alpha e a função ômega do psych exigem que haja correlação entre todas as variáveis. Isto acontece no Saeb regular pelo planejamento por BIB (blocos incompletos balanceados). Mas não ocorre em alguns planejamentos incompletos não balanceados.

Estas definições podem ser vistas no manual do psych nas descrições da função alpha e da função ômega.

Pode-se também calcular empiricamente o coeficiente de confiabilidade pela Teoria de Resposta ao Item (TRI), utilizando-se a equação (1) da definição do coeficiente.

O escore verdadeiro $T_i$do indivíduo i é definido pela esperança de X_i (que é uma variável aleatória). No caso da TRI, é comum estimar a proficiência Θ pela esperança a posteriori de X_i, dado a priori e os parâmetros estimados.

Logo $V(T) = V(\Theta)$.

$V(X) = V(T) + V(E)$ e portanto precisamos estimar $V(E)$.

O erro padrão a posteriori estimado é o erro de $T_i = \Theta_i$, cuja distribuição é suposta ter média 0 (zero). Logo pode-se estimar $V(E_i)$ por $E(E_i^2)$ (esperança do quadrado do erro).

Então

$$V(X) = Variância\ da\ proficiência + média\ do\ quadrado\ do\ erro\ padrão \quad (4)$$

3 Resultados

Aplicamos estas definições para calcular o coeficiente de confiabilidade no exemplo abaixo.

Exemplo: Dados públicos do Saeb 2023 no 5º ano da disciplina de matemática (MT05).

Do arquivo MICRODADOS_SAEB_2023\DADOS\TS_ALUNO_5EF.CSV extraímos os dados dos alunos do 5º ano da disciplina de matemática. A seguir, consideramos somente os alunos com peso amostral > 0 (zero), com os quais as estatísticas de desempenho são calculadas.

Deste arquivo construímos a matriz das observações para podermos rodar o psych. Para cada aluno, construímos um vetor único de respostas dos 77 itens da prova. Itens não apresentados foram recodificados com o símbolo 9. Lembra-se que o Saeb 2023 de MT05 tem 22 cadernos, 21 regulares e um macrotipo. Todo caderno tem somente 22 itens. Os cadernos foram montados a partir de um planejamento de blocos incompletos balanceados (BIB) com 7 blocos de 11 itens, cada caderno é formado por 2 blocos, e cada bloco aparece 3 vezes em cada uma das 2 posições. Além disso, cada par de blocos aparece em um e somente um caderno. Isso garante que há correlação entre todos os itens. Todos os itens são de múltipla escolha.

A partir dos vetores dos alunos, criamos as 77 variáveis com os escores 0 = errado, 1 = certo e NA não apresentado. Nesta matriz. cada linha é um aluno com os seus 77 "escores".

Calculamos as confiabilidades clássicas com a função ômega do psych tanto para o teste completo, como para cada caderno. Utilizou-se somente 1 fator para o cálculo do ômega total.

O arquivo dos alunos também fornece a proficiência estimada $F = PROFICIENCIA_MT$ e seu erro padrão $EP = ERRO_PADRAO_MT$.

Pode-se, portanto, calcular o coeficiente de confiabilidade empírico diretamente pela fórmula, de novo para todos os alunos e para os alunos de cada caderno.

$$\text{coeficiente de confiabilidade empírico} = V(F) \,/\, (V(F) + E(EP^2)) \quad (5)$$

O pacote mirt (Chalmers, 2012), calcula esta confiabilidade empírica para todos os alunos através da rotina empirical_rxx, mas é necessário ter o objeto mirt da calibração.

A tabela 1 fornece os valores das confiabilidades clássicas e da empírica, onde caderno 0, inclui todos os itens.

Tabela 1: **Valores de alpha, G6, ômega total e empírica para os dados dos alunos de MT05 com peso positivo.**

caderno	alpha	G6	omega	empírica
0	0.943	0.947	0.943	0.843
1	0.837	0.837	0.839	0.855
2	0.824	0.827	0.827	0.856
3	0.809	0.810	0.812	0.842
4	0.797	0.797	0.800	0.820
5	0.824	0.823	0.827	0.830
6	0.840	0.840	0.842	0.849
7	0.840	0.840	0.842	0.847
8	0.834	0.835	0.836	0.852
9	0.815	0.816	0.818	0.846
10	0.805	0.807	0.808	0.838
11	0.826	0.826	0.829	0.840

12	0.813	0.814	0.816	0.832
13	0.848	0.847	0.849	0.840
14	0.832	0.834	0.834	0.856
15	0.826	0.826	0.829	0.837
16	0.812	0.814	0.814	0.844
17	0.832	0.833	0.834	0.850
18	0.819	0.820	0.821	0.838
19	0.823	0.822	0.826	0.819
20	0.840	0.842	0.842	0.857
21	0.825	0.827	0.828	0.854
22	0.815	0.819	0.818	0.846

Observa-se que os valores para o caderno 0 (zero), com todos os itens são maiores, como esperado para as estatísticas clássicas do que para os de cada um dos cadernos, mas não para a empírica. As 4 estimativas para os cadernos são muito próximas.

A Tabela 3 mostra que a média das confiabilidades empíricas é aproximadamente igual a confiabilidade empírica dos cadernos. Isto é razoável no Saeb, pois os respondentes de cada caderno regular são amostras equivalentes dos alunos e esses cadernos têm comportamentos semelhantes.

A Tabela 2 fornece um resumo da distribuição dos alpha nos cadernos de 1 a 22.

Tabela 2: **Distribuição dos alpha nos cadernos de 1 a 22.**

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.797	0.815	0.825	0.824	0.833	0.848

A Tabela 3 fornece um resumo da distribuição dos das confiabilidades empíricas nos cadernos de 1 a 22.

Tabela 3: **Distribuição das confiabilidades empíricas nos cadernos de 1 a 22.**

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.819	0.838	0.845	0.843	0.851	0.857

3.1 Discussão

O coeficiente de confiabilidade de um teste fornece a informação da qualidade do teste. Em geral considera-se excelente se for maior que 0.90, bom se estiver entre 0.80 e 0.90, razoável se estiver entre 0.70 e 0.80, baixo se estiver entre 0.60 e 0.70, ruim se estiver entre 0.50 e 0.60 e inaceitável se for menor que 0.5, ver George & Mallery 2003.

Portanto os coeficientes dos testes de cada aluno podem ser considerados bons e se o aluno pudesse fazer o teste com os 77 itens, teria um teste excelente.

Chamamos a atenção de que os coeficientes de confiabilidade clássicos só podem ser calculados caso haja correlação entre todos os itens e que a variância da variável escore total tem que ser calculada através da matriz de covariância dos escores totais dos alunos.

Por exemplo, se formos calcular o alpha pela fórmula calculando $V(X) = \sum_i \left(X_i - media(X_i)\right)^2 / (n-1)$, obteríamos alpha = 0.272 e não 0.943.

4 Conclusões e Considerações Finais

Todos os coeficientes de confiabilidade dos itens dos cadernos de teste do Saeb 2023 de MT05 são considerados bons e têm pouca variabilidade. Os coeficientes de confiabilidade clássicos foram praticamente iguais para todos os cadernos. Deve-se, também, calcular a confiabilidade empírica pela Teoria de Resposta ao Item.

Neste caso, a confiabilidade empírica foi semelhante às confiabilidades empíricas dos cadernos e, também por caderno, às confiabilidades clássicas. Ela tem uma vantagem, pois pode ser calculada, mesmo que o planejamento de blocos incompletos não garanta poder calcular a correlação de quaisquer dois itens.

No Saeb, considera-se, itens não respondidos no final do bloco de um caderno, como sendo não apresentados, a variância da variável escore total não pode ser calculada pela fórmula usual da variância, mas sim através da matriz de covariância dos itens.

5 Referências

Chalmers, R.P. MIRT (2012). A Multidimensional Item Response Theory Package for the R Environment. Journal of Statistical Software, Volume 48, Issue 6.

Cronbach, L. J. (1951). Coefficient alpha and the internal structure of tests. Psychometrika, 16(3), 297-334.

George, D.; Mallery, P. (2003). SPSS for Windows Step by Step: A Simple Guide and Reference. 11.0 Update4. ed. Boston: Allyn & Bacon.

Guttman, L. (1945). A basis for analyzing test-retest reliability. Psychometrika, 10(4), 255-282.

Klein, R. (2005). Testes de Rendimento Escolar. Em Dimensões da Avaliação Educacional, org. Alberto de Mello e Souza, Editora Vozes, p.110-138.

McDonald, R. P. (1999). Test theory: A unified treatment. Psychology Press.

R Development Core Team (2013). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. ISBN 3-900051-07-0, URL http://www.R-project.org/.

Revelle,W. (2019) Package psych manual for R. https://personality-project.org/r/psych-manual.pdf