Os propósitos do ENEM

Ewout ter Haar[1], Gabriel Franco Dutra Leite[2], Isac de Oliveira Silveira[3], Pedro Henrique Casquel Ramires[4], Samuel dos Anjos Souza[5]

[1] Instituto de Física – Universidade de São Paulo <ewout@usp.br>

[2] Instituto de Física – Universidade de São Paulo <gabriel.dutra@usp.br>

[3] Instituto de Física – Universidade de São Paulo <isac.olivsilveira@gmail.com>

[4] Instituto de Física – Universidade de São Paulo <casquel@usp.br>

[5] Instituto de Química – Universidade de São Paulo <samuel.dos.anjos@usp.br>

Resumo

Investigamos as características psicométricas do ENEM em relação a um uso concomitante dos propósitos da avaliação de seleção, certificação e monitoramento. Comparamos a dificuldade dos itens com as notas da população e mostramos que os itens do ENEM são difíceis demais para a grande maioria dos candidatos, levando a incertezas padrão nas notas e intervalos de confiança muito grandes. Mostramos que para notas entre 400 e 500 o ENEM fornece pouca informação e que as notas são praticamente indistinguíveis daquelas geradas por padrões de resposta aleatórios. Desta forma, usar o ENEM na para fins de avaliação do ensino público brasileiro desconsideraria informações relevantes sobre alunos com desempenho próximo ou abaixo da média. O uso de Optimal Test Design mostra que as características dos itens do ENEM terão que mudar substancialmente para atender a todos as finalidades demandadas do exame.

Palavras-chave: ENEM; Curvas de Informação; Incerteza de medida; Optimal Test Design.

1 Introdução

Diferentes avaliações padronizadas têm seus diversos propósitos, como monitoramento das suas redes, regulação, responsabilização, seleção e direcionamento de alunos ou para fins formativos e diagnósticos. No Brasil, o ENADE vai acumular seu tradicional papel de regulação e monitoramento de cursos de graduação com uma nova funcionalidade de seleção de indivíduos para concursos (para cursos de licenciatura e medicina). No estado de São Paulo, o SARESP teve uma mudança parecida em 2023, acumulando a função de vestibular para as instituições de ensino superior públicas do estado. Nesta contribuição focaremos no ENEM, que desde 2009 teve como propósito principal a seleção de indivíduos para o ensino superior e que até 2016 (e a partir de 2025) acumula o de certificação do ensino médio. A partir de 2026 o exame substituirá o SAEB no 3° ano do ensino médio, virando um exame censitário e acumulando mais um propósito, o de monitoramento (MEC, 2026) e há chamadas para que sirva ainda para fins de responsabilização (FERNANDES; PAZELLO; SCORZAFAVE, 2024).

Tabela 1. Uma classificação 2x2 de tipos de avaliação, indicando o propósito de avaliações pelas suas consequências e unidade de análise, com exemplos.

	Menos consequências	Mais consequências
Grupos	Monitoramento ● SAEB, SARESP, ENADE ● ENEM > 2026	Regulação e responsabilização ● ENADE, SARESP
Indivíduos	Formativo e diagnóstico ● Sala de aula	Seleção e certificação ● ENEM, ENADE > 2024 ● SARESP > 2023

Traduzido e adaptado de (HO, 2021) pelo autor.

É possível usar um único exame para múltiplos propósitos? A referência "Padrões de Avaliações Educacionais e Psicológicos" expressa dúvidas: "A maioria dos testes educacionais irão servir melhor uma finalidade do que outras; e quanto mais finalidades um teste educacional deve servir, quanto menos é provável que vá servir estas finalidades de forma efetiva". (AERA; APA; NCME, 2014, p. 188), (tradução do autor). A mesma referência localiza o alvo da validação de testes no uso e interpretação dos resultados. As evidências de validade, portanto, se referem ao propósito do teste. A Tabela 1 mostra uma forma de classificar avaliações em termos do seu principal propósito, mostrando que cada vez mais, os mesmos exames são usados para múltiplos propósitos. Nesta contribuição mobilizamos uma perspectiva psicométrica que expõe as dificuldades que isso implica para fins de validade e confiabilidade destas avaliações.

2 Metodologia

A divulgação pelo INEP dos parâmetros TRI dos itens do ENEM, junto dos microdados, permite análises das propriedades psicométricas do exame. O banco de itens utilizado contém aproximadamente 1600 itens para cada área do conhecimento da prova: Linguagens, Códigos e suas Tecnologias (LC), Matemática e suas Tecnologias (MT), Ciências da Natureza e suas Tecnologias (CN), Ciências Humanas e suas Tecnologias (CH)). Primeiro, reproduzimos as notas divulgados pelo INEP usando Python[1] ou bibliotecas de

[1] Veja https://atp.github.io/enem/TRI.html

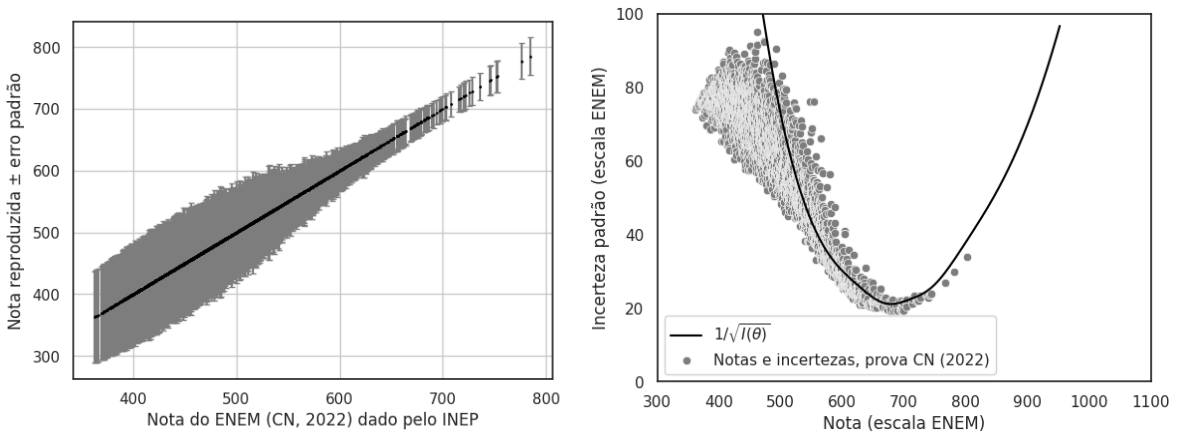
código aberto como o pacote `mirt` (CHALMERS, 2012) a partir dos padrões de resposta nos microdados (Figura 1, esquerda). A reprodução das notas ENEM[2] traz também a incerteza padrão de cada nota, definida como o desvio padrão da distribuição posterior da nota (o INEP usa o método EAP (*Expected a Posteriori*) para calcular as notas). As incertezas condicionais são uma das contribuições deste trabalho, já que as incertezas não são divulgadas pelo INEP.

Com os parâmetros TRI dos itens, podemos caracterizar as provas do ENEM por meio das suas curvas de informação (DE ANDRADE; TAVARES; DA CUNHA VALLE, 2000). Calculamos a informação (dos itens e do teste) do modelo 3PL:

$$I_i(\theta) = \frac{a_i^2 Q_i (P_i - c_i)^2}{P_i (1 - c_i)^2} \text{ e } I_{total}(\theta) = \sum_{i=1}^{45} I_i(\theta)$$

com $Q = 1 - P$ e $P = P(\theta; a, b, c) = c + (1 - c)/(1 + e^{a(b-\theta)})$. O valor $\sigma = 1/\sqrt{I(\theta)}$ pode ser interpretado como incerteza padrão (condicional). Na Figura 1 (direita) mostramos a boa concordância desta curva com as incertezas calculadas pelo pacote `mirt`. As diferenças para notas baixas é devido ao efeito de *shrinkage* da multiplicação pelo *prior* normal do cálculo EAP da nota usado pelo INEP.

Figura 1. Esquerda: notas e incertezas da prova CN de 2022 (amostra de 2000 notas). Direita: as incertezas padrão condicionais conforme calculado pela curva de informação do teste (linha) e pela largura da distribuição posterior (pontos).



Fonte: elaborado pelos autores a partir dos microdados do ENEM.

Para uma prova de seleção ou credenciamento, onde é preciso distinguir bem entre indivíduos, a informação do teste deve ser suficientemente alta em determinadas proficiências. Um exame que visa avaliar de forma precisa toda a população participante deve ter uma curva de informação que é apreciável para todos os possíveis níveis de proficiência dessa população. Vamos avaliar o banco de itens históricos do ENEM sob a ótica da informação fornecida em vários níveis de proficiência, e sua possibilidade de produzir curvas de informação "achatadas" por meio de "Optimal Test Design" (OTD) (van der Linden, 2016). Esta metodologia permite, dado um certo banco de itens, especificar uma curva de informação desejada e escolher, do banco, os itens que minimizem as distâncias até a curva

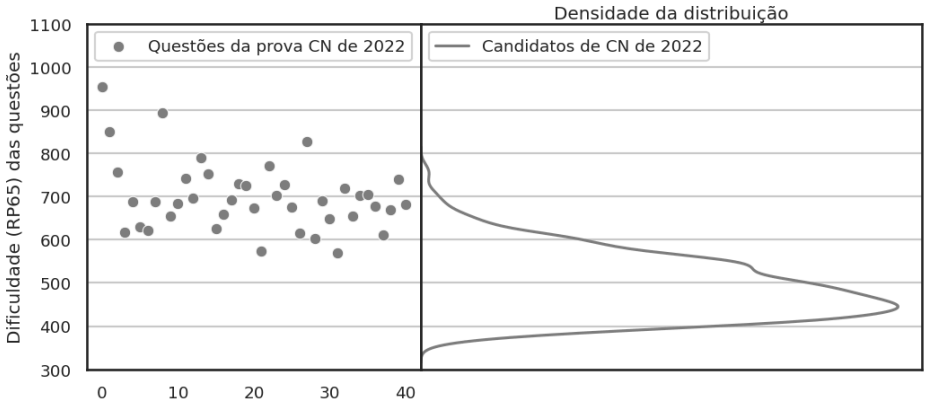
[2] Para transformar as notas na escala TRI N(0,1) para a escala ENEM é necessário usar os seguintes constantes de deslocamento (média) e escala (desvio padrão). MT: 500,0 e 129,7; CN: 501,1 e 113,1; CH: 501,4 e 112,3; LC: 500,0 e 108,1

desejada. Usamos uma implementação de otimização linear (MILP, ou mixed integer linear programming) usando o pacote `scipy.milp` (HUANGFU; HALL, 2018).

3 Resultados

As incertezas padrão grandes para candidatos com notas próximas ou abaixo da média da população (Figura 1), já indicam que o atual ENEM é um instrumento inadequado para fins de avaliação sistêmica ou certificação. O banco de itens usados contém questões difíceis demais para a grande maioria da população de candidatos (que ainda pode ser enviesado para proficiências maiores, por causa da auto-seleção). A média do parâmetro de dificuldade *b* neste banco de aproximadamente 1600 itens por área varia de (1,8±0,9) para a área de MT até (0,7±0,8) para LC na escala TRI, enquanto o parâmetro de discriminação *a* é (2,1±0,8) para todos as àreas.

Figura 2: Uma "mapa de Wright" comparando as dificuldades dos itens com a distribuição das notas dos candidatos.



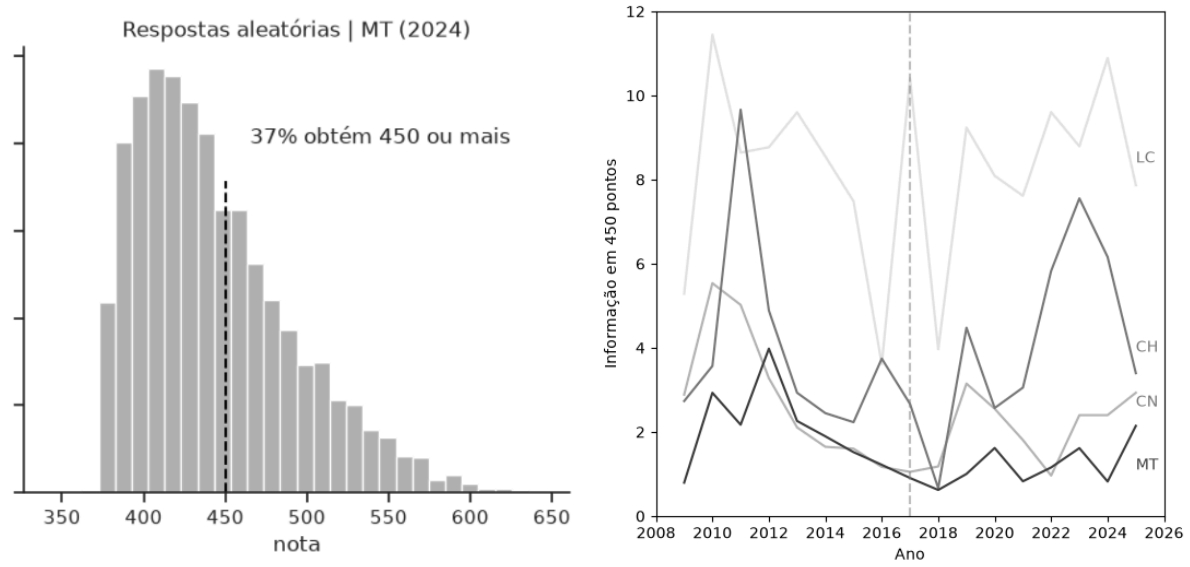
Fonte: elaborado pelos autores a partir dos microdados do ENEM.

Ao exemplo dos autores do relatório técnico da PISA (OECD, 2024, p. 295), calculamos a proficiência em que a probabilidade de resposta é 65% ("RP65") para os itens do ENEM, a partir dos parâmetros da TRI fornecidos pelo INEP. No modelo 3PL usado para o ENEM, esta medida para a dificuldade dos itens é menos ambígua do que usar o parâmetro de dificuldade diretamente. A Figura 2 compara os itens da prova CN de 2022 com a distribuição das habilidades na população usando uma visualização chamada "mapa de Wright" (BRIGGS, 2019; WRIGHT, 1997), mostrando que a grande maioria dos itens está bem acima da proficiência da população.

Dois resultados relevantes para o propósito de certificação são mostrados na Figura 3. A certificação é dada para quem obtém 450 pontos em todas as provas (e 500 na Redação). Entretanto, uma fração grande de padrões de resposta aleatórios geram essa pontuação, devido a quantidade de itens difíceis e a metodologia EAP para calcular a nota (Figura 3, esquerda). Vemos na Figura 3 (direita) que a informação da prova em 450 pontos, que deveria ser apreciável, está muito baixa, e, aparentemente, sem relação com o fato da política pública estar em vigor (antes de 2017) ou não (após 2017). É notável o valor baixo da informação, não passando de 4 para MT e CN, comparado com 20-30 para notas por volta de 700 (Figura 4) e tendo incertezas padrão maior do que meio desvio padrão (mais que 50 pontos).

Figura 3. Esquerda: notas obtidas por simulação de respondentes aleatórios (chance de 0.2 de acerto). Direita: a informação do ENEM em 450 pontos (prova principal) entre 2009 e 2025. A linha

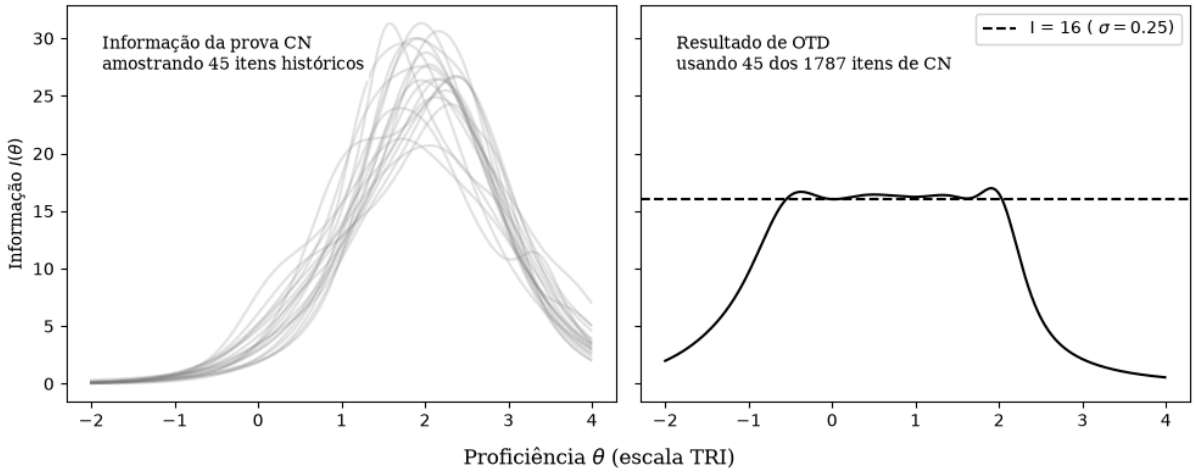
pontilhada representa o momento em que o ENEM deixou de certificar o ensino médio (voltou em 2025).



Fonte: elaborado pelos autores a partir dos microdados do ENEM.

Um exame que atende os três propósitos: seleção, certificação e monitoramento deve fornecer informação suficiente em todo o intervalo de proficiências da população avaliada. A Figura 4 (esquerda) mostra que os exames analisados fornecem pouca informação para os candidatos com uma proficiência média ou abaixo dela. Para fins de argumentação, podemos especificar que estaríamos satisfeitos com uma informação mínima de 16 (0,25 desvios padrão de incerteza) entre $-1 < \theta < 2$ e perguntar se é possível, em princípio, construir uma prova assim com itens do banco de itens utilizados. Na Figura 4 (direita) mostramos que o algoritmo MILP consegue escolher 45 dos 1600 itens da área CN quando os pontos de controle começam em -0,5. Porém o problema não é viável para as áreas de MT, CN e CH se fixamos a informação mínima em 16 para $\theta > -1$, simplesmente porque não há itens suficientes com b < 0.

Figura 4. Esquerda: 20 curvas de informação, cada uma selecionando aleatoriamente uma amostra de 45 itens do banco histórico de itens da área CN. Direita: uma curva de informação usando 45 itens do mesmo banco, escolhido pelo algoritmo MILP, com uma especificação que a informação mínima deveria ser 16 em algumas proficiências de controle de -0,5 até 2.



Fonte: elaborado pelos autores a partir dos microdados do ENEM.

4 Considerações Finais

Mostramos que provas montadas a partir da série histórica dos itens do ENEM não são adequadas para avaliações com três propósitos concomitantes: seleção, certificação e monitoramento, uma vez que não fornecem informação suficiente para todos os níveis de proficiência da população avaliada. Seria possível encomendar e incluir itens mais fáceis nos exames, mas isso, inevitavelmente, viria às custas da informação na região de altas proficiências, tornando o processo de seleção ainda mais sujeito às incertezas de medida. Desta forma, construir itens com alta discriminação (mais informativos) e baixa dificuldade é urgente para assegurar a qualidade da avaliação para fins de monitoramento e ainda mais para responsabilização.

5 Referências

AERA; APA; NCME. **Standards for educational and psychological testing**. Washington, DC: American Educational Research Association, 2014.

BRIGGS, D. C. Interpreting and visualizing the unit of measurement in the Rasch Model. Measurement, v. 146, p. 961–971, nov. 2019.

CHALMERS, R. P. mirt: A Multidimensional Item Response Theory Package for the R Environment. **Journal of Statistical Software**, v. 48, n. 6, 2012.

DE ANDRADE, D. F.; TAVARES, H. R.; DA CUNHA VALLE, R. Teoria da Resposta ao Item: conceitos e aplicações. **ABE, São Paulo**, 2000.

FERNANDES, R.; PAZELLO, E. T.; SCORZAFAVE, L. G. Exames de Ingresso no Ensino Superior, Viés de Seleção e Accountability Educacional: Uma Análise do ENEM. 2024.

HO, A. Questions to ask about educational tests. Disponível em: <https://scholar.harvard.edu/files/andrewho/files/testquestions.pdf>.

HUANGFU, Q., HALL, J. A. J.. Parallelizing the dual revised simplex method, *Mathematical Programming Computation*, **10** (1), 119-142, 2018. DOI: 10.1007/s12532-017-0130-5

MEC. **PORTARIA MEC Nº 422, DE 15 DE MAIO DE 2026 - DOU - Imprensa Nacional**. Disponível em: <https://www.in.gov.br/web/dou/-/portaria-mec-n-422-de-15-de-maio-de-2026-706288933>.

OECD. **PISA 2022 Technical Report**. [s.l.] OECD, 2024.

VAN DER LINDEN, Wim J. **Optimal Test Design**. *In*: VAN DER LINDEN, Wim J. (Org.). **Handbook of item response theory**. Boca Raton: CRC Press, Taylor & Francis Group, 2016. v. 3.

WRIGHT, B. D. A History of Social Science Measurement. **Educational Measurement: Issues and Practice**, v. 16, n. 4, p. 33–45, 1997.