Inteligência Artificial Generativa aplicada à avaliação educacional: desenvolvimento e validação de um gerador automatizado de itens

Karina Stefanin Pereira[1], Maria Clara Vieira Jacheta[2], Mônica Roberta Antônio[3], Ricardo Batista[4]

[1] SESI-SP kstefanin@sesisp.org.br
[2] SESI-SP mariaclara@sesisp.org.br
[3] SESI-SP monica.antonio@sesisp.org.
[4] SESI-SP ricardo.batista@sesisp.org.br

Resumo

Esta pesquisa investiga o desenvolvimento de um gerador automatizado de itens baseado em Inteligência Artificial Generativa para a Plataforma de Estudos Personalizados (PEP) do SESI-SP. Diferentemente do uso isolado de ferramentas genéricas de IA, a solução própria foi concebida para incorporar descritores curriculares, critérios pedagógicos e parâmetros técnicos de elaboração de itens. O estudo, de natureza exploratória e aplicada, analisou ciclos de geração, revisão especializada e calibração das instruções do sistema. Os resultados preliminares indicam que comandos genéricos favorecem a adequação temática, mas não asseguram o alinhamento à habilidade cognitiva pretendida. O refinamento dos prompts e das regras do gerador, associado à validação humana, ampliou a coerência entre suporte, comando, alternativas e operação cognitiva. Conclui-se que a solução apresenta potencial para apoiar a produção de itens em larga escala, desde que submetida a critérios técnicos rigorosos, supervisão especializada e aprimoramento contínuo.

Palavras-chave: Inteligência Artificial Generativa; Avaliação Educacional; Elaboração de Itens; Psicometria; Personalização da Aprendizagem.

1. Introdução

A utilização de sistemas de Inteligência Artificial Generativa na educação tem ampliado as possibilidades de produção, adaptação e organização de conteúdos. Na avaliação educacional, entretanto, a geração de questões exige mais do que correção temática ou linguística. Um item deve apresentar coerência interna, clareza, adequação ao público-alvo e alinhamento entre o descritor curricular, o suporte, o comando e a operação cognitiva mobilizada pelo estudante.

No contexto da Plataforma de Estudos Personalizados (PEP) do SESI-SP (recurso disponibilizado aos estudantes desde 2025), a necessidade de fornecer questões em escala, associada à diversidade de componentes curriculares e habilidades, motivou o desenvolvimento de um gerador automatizado próprio. Assim, o processo investigado não se limita ao uso de ferramentas abertas ou isoladas de IA. Trata-se de uma solução concebida para receber parâmetros estruturados, aplicar regras de elaboração e produzir propostas de itens orientadas pelas necessidades pedagógicas e avaliativas da instituição.

A criação de uma solução especializada permite maior controle sobre as instruções encaminhadas ao modelo generativo e favorece a padronização dos produtos. Ao mesmo tempo, não elimina a necessidade de análise especializada, pois respostas linguisticamente plausíveis podem conter inconsistências conceituais, pistas de resposta, alternativas pouco funcionais ou desalinhamento cognitivo. A pesquisa considera, portanto, a IA como recurso de apoio ao trabalho técnico, e não como substituta da autoria e da validação humanas.

Partindo desse cenário, o estudo examina o desenvolvimento e o aperfeiçoamento do gerador, com atenção especial aos ciclos de calibração dos prompts e às análises realizadas por especialistas. Busca-se compreender em que condições a automação pode contribuir para ganhos de escala e produtividade, preservando os critérios de qualidade requeridos na elaboração de itens avaliativos.

2. Objetivos

O objetivo geral é investigar o potencial de um gerador automatizado próprio, baseado em Inteligência Artificial Generativa, para apoiar a elaboração de itens avaliativos destinados à Plataforma de Estudos Personalizados do SESI-SP.

Como objetivos específicos, pretende-se: analisar a qualidade técnica e pedagógica dos itens gerados; verificar o alinhamento entre descritores curriculares e habilidades cognitivas; comparar os resultados obtidos com instruções genéricas e calibradas; identificar limitações recorrentes no processo de geração; e examinar a contribuição da validação humana para o refinamento das questões produzidas.

3. Metodologia

A pesquisa caracteriza-se como exploratória e aplicada, pois investiga um problema concreto da produção de itens e acompanha o aprimoramento de uma solução tecnológica desenvolvida para esse fim. O objeto de análise é o gerador automatizado próprio utilizado na elaboração preliminar de itens para a PEP.

O funcionamento do gerador foi estruturado a partir de entradas relacionadas ao componente curricular, ao ano ou etapa de ensino, ao descritor, à habilidade, ao nível de complexidade esperado e às características do item. Essas informações orientam a geração do suporte, do comando, da alternativa correta e dos distratores. O sistema também recebe regras destinadas a reduzir ambiguidades, pistas involuntárias e incompatibilidades entre a tarefa solicitada e a habilidade avaliada.

O percurso metodológico foi organizado em ciclos. No primeiro, foram utilizadas instruções mais amplas para observar o comportamento inicial do gerador e mapear padrões de inadequação. No segundo, os prompts e as regras foram refinados com base nas ocorrências identificadas. Nos ciclos seguintes, novas versões dos itens foram produzidas e submetidas à revisão técnica, alimentando ajustes sucessivos no sistema.

A análise qualitativa considerou, principalmente: aderência ao descritor; correspondência entre comando e operação cognitiva; pertinência e suficiência do suporte; clareza e objetividade da linguagem; plausibilidade dos distratores; unicidade da resposta correta; ausência de pistas; correção conceitual; e adequação ao público-alvo. A validação foi

realizada por profissionais com experiência em currículo e avaliação educacional, preservando a decisão humana sobre a aprovação, a revisão ou o descarte de cada item.

Por se tratar de pesquisa em desenvolvimento, esta etapa concentra-se na qualidade técnica do processo de geração e revisão. A análise psicométrica empírica dos itens, dependente de aplicação e dados de resposta dos estudantes, constitui uma etapa posterior do processo de validação.

4. Resultados

Os resultados preliminares demonstram que o gerador apresenta facilidade para produzir questões relacionadas ao conteúdo informado. Contudo, a adequação temática, isoladamente, não garante que o item mobilize a habilidade cognitiva prevista no descritor. Nas versões iniciais, observaram-se situações em que o conteúdo estava correto, mas o comando solicitava reconhecimento ou localização de informação quando se pretendia avaliar análise, inferência, comparação ou aplicação.

As ocorrências reforçam a importância de distinguir conteúdo e operação cognitiva. Quando o prompt informava apenas tema, ano escolar e descritor, o modelo tendia a privilegiar elementos lexicais do conteúdo. Com a explicitação da ação cognitiva, das condições de realização da tarefa e das relações esperadas entre suporte e comando, os itens passaram a apresentar maior aderência ao propósito avaliativo.

O desenvolvimento de um gerador próprio constituiu um diferencial relevante. Ao centralizar parâmetros, regras e orientações técnicas, a solução reduziu a dependência de comandos elaborados pontualmente por diferentes usuários. Isso favoreceu maior uniformidade no processo e tornou possível registrar ajustes que podem ser reutilizados em novas gerações, transformando as aprendizagens da equipe em regras do sistema.

A calibração mostrou-se um processo contínuo. A cada ciclo, inconsistências identificadas pela equipe foram convertidas em orientações mais precisas. Entre os aspectos aperfeiçoados, destacam-se a articulação entre suporte e comando, a construção de distratores plausíveis, a delimitação da resposta correta e a compatibilidade da linguagem com a etapa de ensino. Esse movimento indica que a qualidade não resulta apenas da escolha do modelo de IA, mas principalmente da arquitetura de instruções e dos critérios de revisão que orientam seu uso.

A validação humana permaneceu indispensável. Mesmo após o refinamento, alguns itens demandaram ajustes de precisão conceitual, clareza, contextualização ou nível de exigência. A supervisão especializada também evitou que a fluidez textual fosse tomada como evidência suficiente de qualidade. Desse modo, o gerador atua como ferramenta de apoio à proposição e ao refinamento inicial, enquanto a decisão técnica permanece sob responsabilidade de profissionais qualificados.

Os achados apontam potencial de ganho de escala e agilização, mas também recomendam cautela. A adoção institucional da solução requer monitoramento sistemático, registro das versões, critérios explícitos de aprovação e revisão periódica das regras. Além disso, o desempenho do gerador deve ser acompanhado por indicadores de qualidade e, quando houver aplicação dos itens, por evidências empíricas provenientes das respostas dos estudantes.

5. Conclusão

A pesquisa evidencia que a Inteligência Artificial Generativa pode contribuir para a elaboração de itens avaliativos quando incorporada a uma solução própria, especializada e submetida a governança técnica. O gerador automatizado desenvolvido para a PEP diferencia-se do uso de ferramentas genéricas por organizar parâmetros curriculares e regras de elaboração em um fluxo estruturado, favorecendo maior controle e padronização.

Os resultados preliminares mostram que instruções genéricas não asseguram alinhamento cognitivo, embora possam produzir textos adequados ao conteúdo. A calibração dos prompts e das regras, articulada à validação humana, ampliou a coerência dos itens e permitiu transformar problemas recorrentes em oportunidades de aperfeiçoamento do sistema.

Conclui-se que o potencial da solução está associado à integração entre tecnologia, conhecimento pedagógico e fundamentos da avaliação educacional. Sua utilização responsável pressupõe supervisão especializada, ciclos contínuos de calibração e validação, além de futura análise empírica do comportamento dos itens. Nessas condições, o gerador pode apoiar a ampliação da produção sem relativizar a qualidade técnica necessária aos processos avaliativos.

6. Referências

BRUNO, A. R. Itens digitais na avaliação: experiências com as inteligências artificiais generativas na área de Língua Portuguesa. *teccogs: Revista Digital de Tecnologias Cognitivas*, n. 32, 2025.

BLOOM, Benjamin S. et al. Taxonomy of educational objectives: the classification of educational goals. Handbook I: cognitive domain. New York: Longmans, Green, 1956.

LIMA, F. E. A.; CASTRO, J. B. Avaliação da qualidade de itens de Matemática gerados por Inteligência Artificial Generativa: um estudo com base na Teoria Clássica dos Testes. *Revista Intersaberes*, v. 21, e26do302, 2026.

PEP. Guideline para elaboração de itens avaliativos PEP: orientações técnicas para elaboração, revisão e validação de itens de múltipla escolha. *Versão consolidada*. Julho de 2026. Documento técnico institucional do Núcleo de Avaliação Educacional SESI-SP.

PASQUALI, Luiz. Psicometria: teoria dos testes na psicologia e na educação. 5. ed. Petrópolis: Vozes, 2017.

UNESCO. Guidance for generative AI in education and research. Paris: UNESCO, 2023.

VIANNA, Heraldo Marelim. Testes em educação. São Paulo: IBRASA, 1973.